VERİ MADENCİLİĞİ

DÖNEM PROJE Sİ RAPORU

Metal Döküm Parçalarında Denetimsiz Öğrenme ile Yüzey Anomali Tespiti

---

HOG · LBP · PCA · Local Outlier Factor

Öğrenci Adı:	Irmak Tanrıverdi
Bölüm:	Yapay Zeka Mühendisliği
Öğrenci No:	2302120258
Ders:	Veri Madenciliği
Proje Türü:	Dönem Projesi

Bu rapor, Casting Product Image Data for Quality Inspection veri seti üzerinde gerçekleştirilen anomali tespiti çalışmasının teknik bulgularını sunmaktadır.

1. Giriş

Endüstriyel üretim süreçlerinde kalite kontrol, ürün güvenilirliği açısından kritik öneme sahiptir. Metal döküm parçaların yüzey kusurları — çatlaklar, gözenekler ve deformasyonlar — parçanın dayanıklılığını doğrudan etkileyerek ciddi güvenlik risklerine yol açabilmektedir [1]. Geleneksel manuel denetim yöntemleri yavaş, öznel ve maliyetli olduğundan, otomatik görüntü tabanlı sistemlere olan ihtiyaç giderek artmaktadır [2]. Bu çalışmada, paslanmaz çelik dalgıç pompa pervane (impeller) yüzey görüntüleri için denetimsiz öğrenme tabanlı bir anomali tespit sistemi geliştirilmiştir. Projenin temel motivasyonu şu üç sorundur:

1. **Etiketli anomali verisi yetersizliği:** Üretim hatası örnekleri doğası gereği nadir görülür; dolayısıyla dengeli ve etiketlenmiş bir veri seti oluşturmak pratik açıdan oldukça güçtür.
2. **Bilinmeyen hata tipleri:** Önceden tanımlanmamış veya hiç karşılaşılmamış yüzey kusurlarını geleneksel sınıflandırıcılarla tespit etmek mümkün değildir.
3. **Yüksek görsel çeşitlilik:** Aydınlatma koşulları, kamera açısı ve yüzey doku farklılıkları, görüntü tabanlı sistemlerin genelleme kapasitesini kısıtlamaktadır.

Bu zorlukların üstesinden gelmek amacıyla, yalnızca hatasız (normal) parçalar üzerinde eğitilen bir *novelty detection* yaklaşımı benimsenmiştir. Üç farklı özellik çıkarım yöntemi karşılaştırılmış; HOG (Histogram of Oriented Gradients), çok ölçekli LBP (Local Binary Patterns) ve bu iki yöntemin birleşimi olan HOG+LBP, Local Outlier Factor (LOF) modeli ile birlikte değerlendirilmiştir.

2. İlgili Çalışmalar

Görüntü tabanlı anomali tespiti, bilgisayarlı görü ve makine öğrenmesi literatüründe geniş yer tutan bir araştırma alanıdır [8]. Erken dönem çalışmalar GMM ve KDE gibi istatistiksel yoğunluk tahmin yöntemlerine dayanmış; ancak bu yöntemler yüksek boyutlu veride yetersiz kalmıştır [9].

2.1. Özellik Tabanlı ve Derin Öğrenme Yaklaşımları

Klasik yöntemler arasında HOG ve LBP öne çıkmaktadır. HOG görüntü gradyanlarını histogramlarla kodlayarak şekil bilgisini özetlerken [3], LBP her pikseli komşularıyla karşılaştırarak doku bilgisini sayısal bir kodla ifade eder [4]. One-Class SVM [6], Isolation Forest [7] ve LOF [5] bu özellik vektörleri üzerinde etkin anomali tespiti sağlamaktadır. Son yıllarda Convolutional Autoencoder [2] ve Normalizing Flows [10] gibi derin öğrenme modelleri yüksek performans sergilemiş; ancak büyük veri ve hesaplama kaynağı gerektirmeleri, sınırlı koşullarda klasik yöntemleri rekabetçi kılmaktadır.

2.2. Bu Çalışmanın Konumlandırılması

Bu proje, HOG+LBP özellik kombinasyonu ve LOF modelini sanayi kalite kontrolü bağlamında sistematik biçimde karşılaştırmaktadır. Çok ölçekli LBP kullanımı, PCA boyut indirgeme ve Youden eşiği seçimi bu çalışmayı literatürden ayırt eden temel tasarım kararlarıdır.

3. Veri Seti ve Ön İşleme

3.1. Veri Seti

Çalışmada Kaggle üzerinde kamuya açık olarak sunulan *Casting Product Image Data for Quality Inspection* veri seti kullanılmıştır [11]. Veri seti, bir paslanmaz çelik dalgıç pompa pervane (impeller) üretim hattından elde edilen, üstten çekilmiş gri tonlamalı görüntülerden oluşmaktadır. Görüntüler iki sınıfa ayrılmaktadır:

- **ok_front:** Hatasız, kabul edilebilir yüzey kalitesine sahip parçalar (Normal sınıf).
- **def_front:** Çatlak, gözenek veya deformasyon gibi yüzey kusurları barındıran parçalar (Anomali sınıfı).

Tüm görüntüler 128×128 piksel boyutuna yeniden örneklenmiştir. Veri seti, %80 eğitim ve %20 test olarak bölünmüş; sınıf dengesini korumak amacıyla stratifiye örnekleme uygulanmıştır. Toplam görüntü sayısı ve sınıf dağılımı Tablo 1 ile özetlenmiştir.

Tablo 1: Veri seti sınıf dağılımı

Küme	Normal	Anomali	Toplam
Eğitim	2519	3361	5880
Test	628	842	1470

Ancak, modelin yalnızca normal sınıf verileriyle eğitildiği göz önüne alındığında, eğitim setindeki anomali örnekleri tamamen göz ardı edilmiş; LOF modeli yalnızca eğitim setindeki normal görüntülere uygulanmıştır.

3.2. Görüntü Ön İşleme

Ham görüntüler, özellik çıkarımı öncesinde iki adımlı bir ön işleme sürecinden geçirilmiştir:

3.2.1. CLAHE – Kontrast Sınırlı Uyarlanabilir Histogram Eşitleme

Contrast Limited Adaptive Histogram Equalization (CLAHE), görüntüyü bölgelere (tile) ayırarak her bölgede bağımsız kontrast iyileştirmesi uygular; bu sayede düşük kontrastlı

bölgelerdeki ince yüzey yapıları ön plana çıkar. Kullanılan parametreler: clipLimit $= 2.0$, tileGridSize $= 8 \times 8$. Ardından 3×3 boyutlu Gaussian filtresi uygulanarak kamera ve sıkıştırmadan kaynaklanan yüksek frekanslı gürültü bastırılmış; HOG gradyan hesaplamalarının kararlılığı artırılmıştır.

4. Özellik Çıkarımı

4.1. HOG – Yönlü Gradyan Histogramı

HOG (Histogram of Oriented Gradients), görüntüdeki kenar ve şekil bilgisini yerel yoğunluk gradyanlarının yönleri üzerinden kodlayan bir tanımlayıcıdır [3]. 8×8 piksellik hücrelerde gradyanlar 12 yönelimli histograma dönüştürülür; 2×2 hücreli bloklar üzerinde L2-Hys normalizasyonu ile aydınlatma değişimine karşı dayanıklılık sağlanır. 128×128 görüntü için yaklaşık 34.596 boyutlu vektör üretilmekte olup bu boyutluluk PCA ile azaltılmaktadır.

4.2. Çok Ölçekli LBP – Yerel İkili Desen

LBP (Local Binary Patterns), her pikseli komşu piksellerle karşılaştırarak bir ikili kod üretir ve doku bilgisini sayısal bir histogramla özetler [4]. Bu çalışmada tek bir ölçek yerine üç farklı ölçek parametresi ile çok ölçekli LBP kullanılmıştır:

Tablo 2: Çok ölçekli LBP parametreleri

Yarıçap (R)	Komşu Sayısı (P)	Odaklandığı Yapı
1	8	İnce, piksel düzeyindeki dokular
2	16	Orta ölçekli yüzey desenleri
3	24	Kaba, geniş kapsamlı yapılar

Her ölçek için normalize edilmiş bir histogram üretilmektedir. Tek bir ölçeğin yakalayamadığı hem mikro düzey hem de makro düzey doku farklılıklarını aynı anda modelleme kapasitesi, çok ölçekli yaklaşımın en önemli avantajıdır. Üç histogramın birleştirilmesi, $3 \times (P + 2)$ boyutlu bir özellik vektörü oluşturmaktadır.

4.3. HOG+LBP Birleşimi

HOG ve LBP özellik vektörlerinin yatay birleştirme (concatenation) yöntemiyle elde edilen HOG+LBP temsili, şekil ve doku bilgisini tek bir vektörde toplamayı amaçlamaktadır. Birleştirme işlemi sonucunda vektör boyutu HOG ve LBP boyutlarının toplamına eşit olmakta; bu durum PCA boyut indirgeme adımını daha da önemli kılmaktadır.

5. Boyut İndirgeme ve Model

5.1. RobustScaler ile Özellik Normalizasyonu

HOG ve LBP özellik vektörleri farklı büyüklük ölçeklerine sahip olduğundan, doğrudan birleştirilmeleri ya da model girdisi olarak kullanılmaları bozuk sonuçlara yol açabilmektedir. Bu nedenle her özellik kümesi, `RobustScaler` ile normalize edilmiştir. StandardScaler'ın aksine, RobustScaler medyan ve çeyrekler arası aralık (IQR) kullanarak çarpıklığa dayanıklı bir normalizasyon sağlar:

$$x' = \frac{x - \text{median}(x)}{\text{IQR}(x)} \tag{1}$$

Bu tercih, sanayi görüntülerindeki yoğunluk aykırı değerlerinin ölçeklemeyi bozmayacağını garanti altına almaktadır.

5.2. PCA – Temel Bileşen Analizi

Binlerce boyutlu özellik vektörlerinin LOF gibi mesafe tabanlı modellerde doğrudan kullanılması *boyutsallık laneti* (curse of dimensionality) nedeniyle sakıncalıdır [9]. Bu sorunu gidermek amacıyla, varyansın %95'ini açıklayan temel bileşenler korunacak şekilde PCA uygulanmıştır.

Her üç özellik kümesi için PCA sonrası bileşen sayıları aşağıdaki gibi gerçekleşmiştir:

- **HOG:** $\approx$ 150–200 bileşen
- **LBP:** $\approx$ 20–30 bileşen (daha kompakt temsil)
- **HOG+LBP:** $\approx$ 200–250 bileşen

PCA, yalnızca eğitim setindeki normal örnekler üzerinde fitlenmekte; test seti bu dönüşüme tabi tutulmaktadır.

5.3. Local Outlier Factor (LOF)

LOF, 2000 yılında Breunig ve arkadaşları tarafından önerilen, yerel yoğunluk tabanlı bir anomali tespit algoritmasıdır [5]. Her veri noktasının anormallik skoru, komşularının yerel erişilebilirlik yoğunlukları ile kıyaslanarak hesaplanır:

$$\text{LOF}_k(p) = \frac{\frac{1}{|N_k(p)|} \sum_{o \in N_k(p)} \text{lrd}_k(o)}{\text{lrd}_k(p)} \tag{2}$$

Burada $\text{lrd}_k(p)$ noktasının yerel erişilebilirlik yoğunluğunu, $N_k(p)$ ise k-en yakın komşu kümesini temsil etmektedir. LOF ≈ 1 olan noktalar komşu yoğunluğuna benzer bir bölgede

yer alır (normal); LOF $\gg 1$ olan noktalar ise seyrek bir bölgede bulunarak anomali olarak işaretlenir.

Bu çalışmada LOF, `novelty=True` modu ile kullanılmıştır; model yalnızca normal örneklerle eğitilmiş, test örnekleri `decision_function` aracılığıyla değerlendirilmiştir. Optimal k değeri hiperparametre araması ile belirlenmiştir.

5.3.1. Hiperparametre Optimizasyonu

Komşu sayısı k parametresi, $\{5, 10, 20, 30, 50, 75, 100\}$ adayları üzerinden ızgara aramasıyla optimize edilmiştir. Her aday için eğitim seti AUC skoru hesaplanmış ve en yüksek AUC değerini veren k seçilmiştir. Kirlilik oranı (contamination) sabit olarak 0.10 alınmıştır.

5.4. Youden Eşiği ile Karar Sınırı Belirleme

Standart 0.5 eşiği yerine, hassasiyet ve duyarlılık arasındaki optimum dengeyi sağlayan Youden İstatistiği ile karar eşiği otomatik olarak belirlenmiştir:

$$J = \text{TPR} - \text{FPR} \tag{3}$$

ROC eğrisi üzerinde J değerini maksimize eden eşik noktası, nihai ikili sınıflandırma için kullanılmıştır. Bu yaklaşım, farklı özellik kümeleri arasındaki adil bir karşılaştırmayı mümkün kılmaktadır.

6. Deneysel Bulgular

6.1. Karşılaştırmalı Performans Metrikleri

Üç özellik kümesi için test seti üzerinden elde edilen performans değerleri Tablo 3 ile sunulmuştur.

Tablo 3: HOG, LBP ve HOG+LBP özellik kümelerinin LOF modeli ile karşılaştırmalı performansı

Özellik Kümesi	AUC	Precision	Recall	F1-Skor
HOG	0.951	0.89	**0.98**	0.93
LBP	**0.964**	**0.94**	0.89	0.92
HOG+LBP	0.951	0.90	0.95	0.93

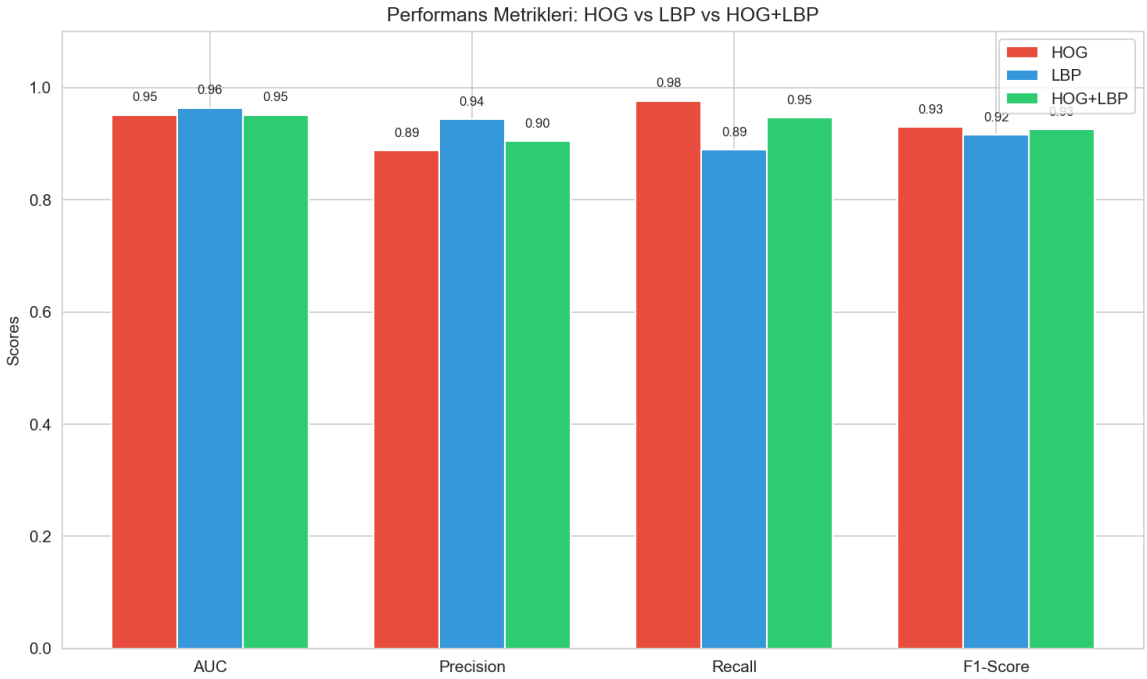

Şekil 1: HOG, LBP ve HOG+LBP yöntemlerinin AUC, Precision, Recall ve F1-Skor karşılaştırması

Sonuçlar birkaç önemli gözlemi ortaya koymaktadır:

- **LBP en yüksek AUC değerini** (0.964) elde ederek, doku bilgisinin yüzey anomalisi tespitinde gradyan bilgisinden daha ayırt edici olduğunu kanıtlamaktadır.
- **HOG en yüksek Recall'u** (0.98) sağlamaktadır. Yüksek recall, hatalı parçaların gözden kaçırılmadığı anlamına gelir; kritik güvenlik uygulamalarında bu değer ön plana çıkmaktadır.
- **LBP en yüksek Precision'a** (0.94) sahiptir. Yüksek precision, sistemin yanlış alarm üretme eğiliminin düşük olduğunu gösterir; bu özellik maliyetli duruş gerektiren üretim hatları için avantajlıdır.
- **HOG+LBP birleşimi, beklenen sinerjik iyileşmeyi sağlayamamıştır.** HOG+LBP'nin AUC değeri HOG ile aynı kalırken F1 skoru da HOG ile eşittir. Boyut artışının eklediği gürültü bileşenleri muhtemelen birleşim faydasını dengelemiştir.

6.2. ROC Eğrisi Analizi

Şekil 2'de sunulan karşılaştırmalı ROC eğrisi, LBP'nin özellikle düşük FPR bölgesinde (FPR < 0.1) belirgin bir avantaj sergilediğini göstermektedir. Bu bölge, gerçek pozitif oranın hızlı arttığı, yani modelin az sayıda yanlış pozitifle birlikte çok sayıda gerçek anomaliyi yakaladığı kritik çalışma noktasına karşılık gelmektedir.

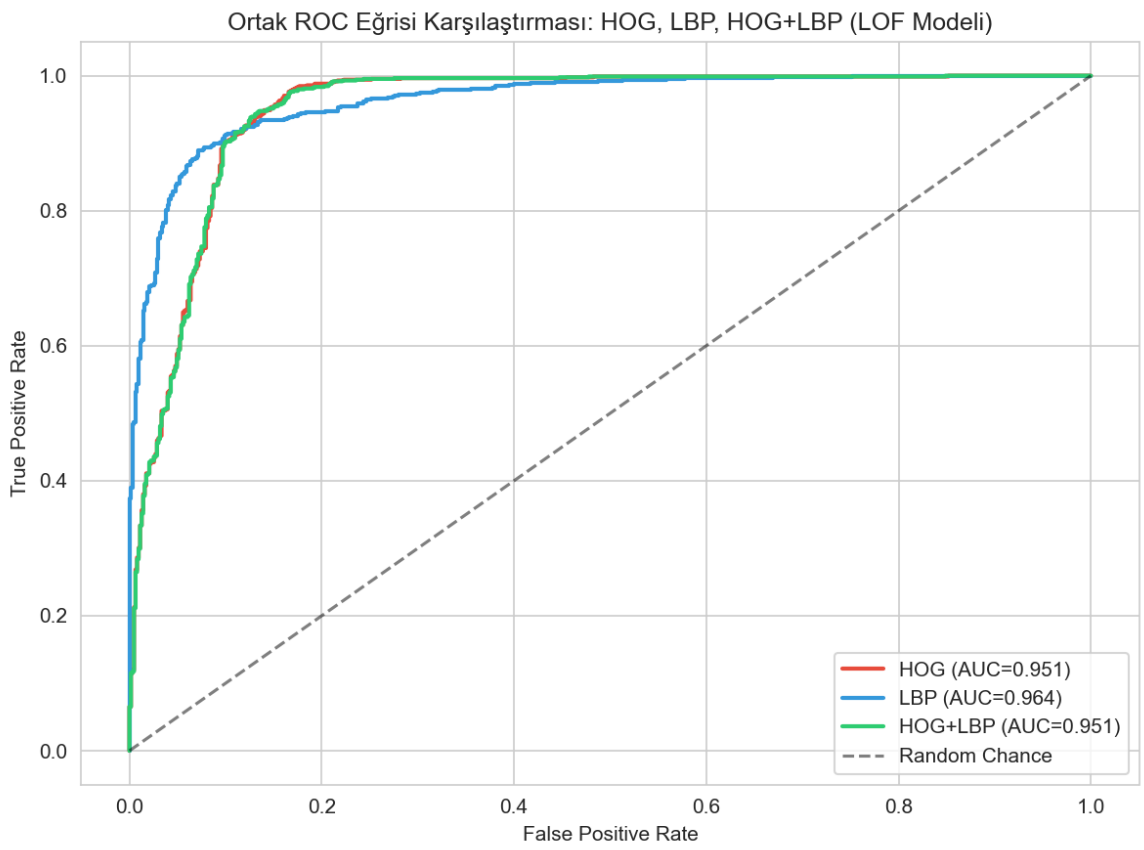

Şekil 2: HOG, LBP ve HOG+LBP modellerinin karşılaştırmalı ROC eğrisi (LOF Modeli)

6.3. Karmaşıklık Matrisleri

HOG modeli için karmaşıklık matrisinde 822 doğru anomali tespiti, 20 kaçan anomali (false negative), 524 doğru normal tahmin ve 104 yanlış alarm (false positive) gözlemlenmiştir. LBP modelinde ise 749 doğru anomali, 93 kaçan anomali, 583 doğru normal ve 45 yanlış alarm elde edilmiştir.

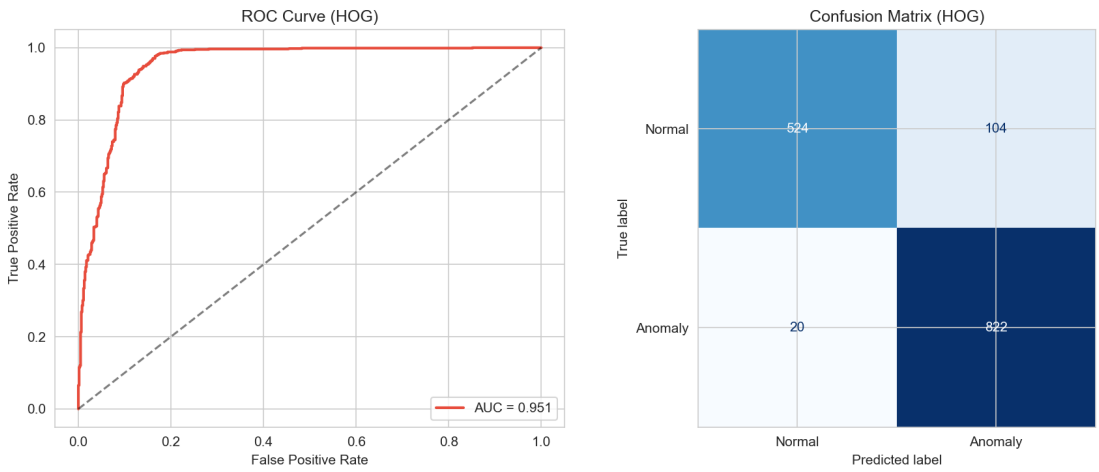

Şekil 3: HOG modeli için ROC eğrisi ve karmaşıklık matrisi

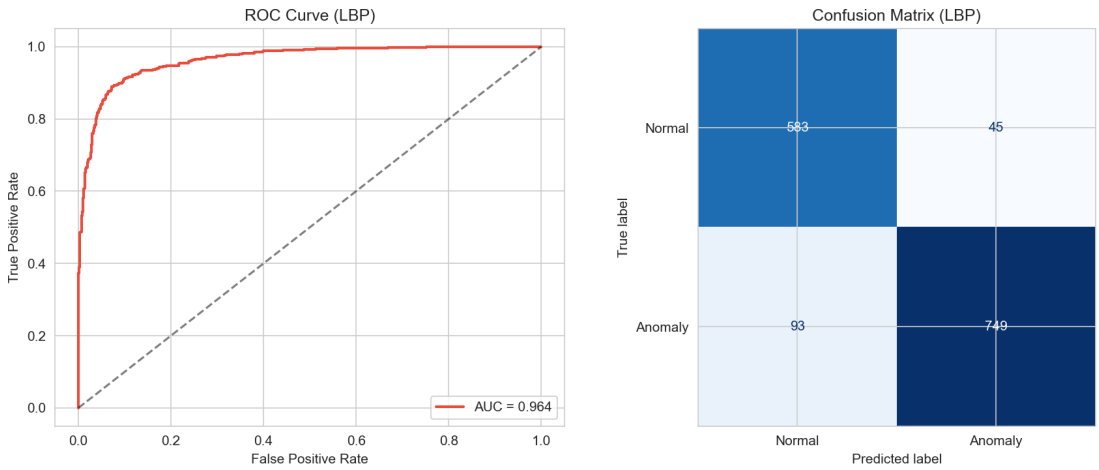

Şekil 4: LBP modeli için ROC eğrisi ve karmaşıklık matrisi

6.4. En Normal ve En Anomalik Görüntüler

HOG+LBP modelinde en düşük LOF skoruna sahip görüntüler üstten bakıldığında mükemmel dairesel simetri gösteren, homojen yüzey dokusuna sahip pervane görüntülerinden oluşmaktadır.

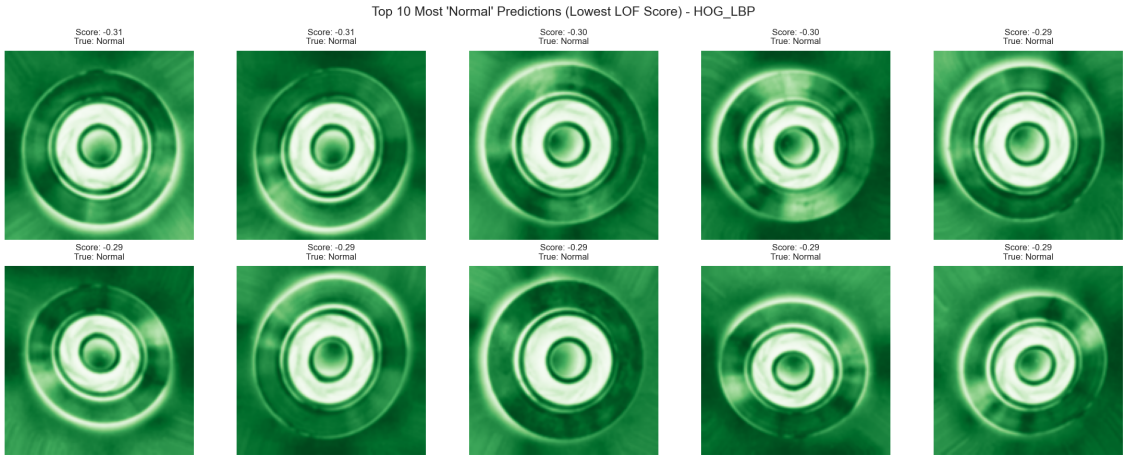

Şekil 5: HOG+LBP modelinde en düşük LOF skoruna sahip (en normal) görüntüler

En yüksek LOF skoruna sahip görüntüler ise asimetrik kenarlara, çatlak izlerine ve parçalanmış yüzey yapısına sahip bileşenlerden oluşmaktadır.

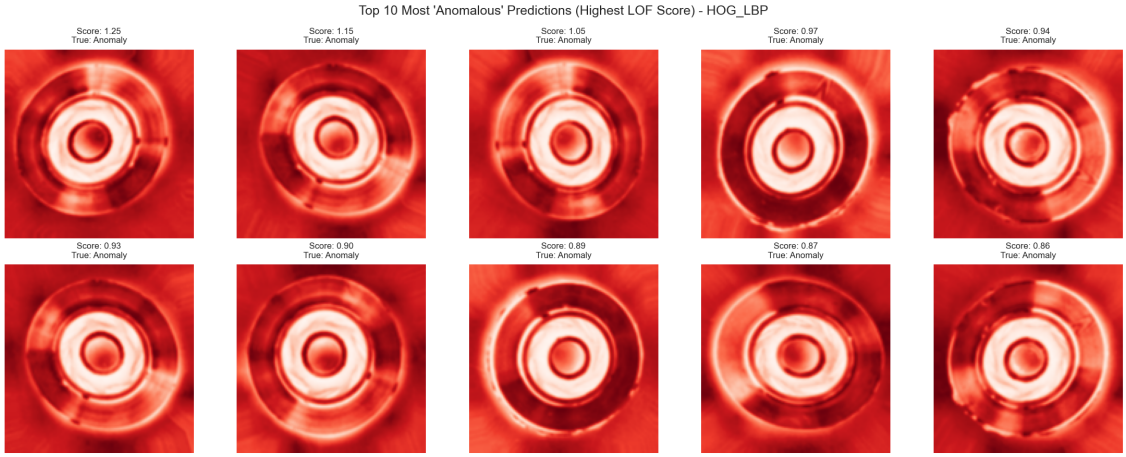

Şekil 6: HOG+LBP modelinde en yüksek LOF skoruna sahip (en anomalik) görüntüler

7. Tartışma

7.1. Neden LBP Daha Başarılı?

Metal döküm parçalarındaki yüzey kusurları öncelikle doku düzeyinde kendini göstermektedir: çatlaklar ve gözenekler yerel piksel ilişkilerini bozar. LBP bu tür mikro düzey bozuklukları doğrudan kodlarken, HOG şekil bilgisini ön plana çıkarmaktadır. Çok ölçekli LBP ($R = 1, 2, 3$) ince çatlaklardan geniş deformasyon izlerine kadar hiyerarşik bir doku profili sunarak bu avantajı pekiştirmektedir.

7.2. HOG+LBP Birleşiminin Beklentileri Karşılamaması

Birleşimin beklenen sinerjiyi sağlayamamasının üç olası açıklaması vardır: (1) HOG'un yüksek boyutlu vektörü PCA sürecinde LBP bileşenlerinin etkisini zayıflatmış olabilir; (2) iki yöntem kısmen örtüşen yapısal bilgi kodladığından tamamlayıcılık potansiyeli sınırlı kalmıştır; (3) eşit ağırlıklı birleştirme daha bilgilendirici olan LBP bileşenlerinin katkısını azaltmıştır.

7.3. Denetimsiz Yaklaşımın Güçlü Yönleri ve Sınırlılıklar

Novelty detection yaklaşımının en belirgin avantajı etiketli anomali verisi gerektirmemesidir; AUC > 0.95 düzeyindeki performans bu yaklaşımın endüstriyel uygulanabilirliğini kanıtlamaktadır. Bununla birlikte 128×128 piksel çözünürlüğü ince yüzey çizgilerinde kayba yol açabilmekte, gri tonlamalı işleme renk tabanlı anormallikleri tespit etmekte yetersiz kalabilmekte ve sonuçlar tek bir ürün geometrisine özgüdür.

8. Gelecek Çalışmalar

Model tarafında One-Class SVM [6] ve Isolation Forest [7] ile doğrudan karşılaştırma yapılabilir; derin öğrenme tarafında ise Convolutional Autoencoder [2] rekonstrüksiyon hatasını anomali skoru olarak kullanan güçlü bir alternatif sunar. Özellik mühendisliği açısından ağırlıklı birleştirme, Gabor filtreleri ve HSV renk uzayı tabanlı özellikler araştırılabilir. Geliştirilen model ONNX formatına dönüştürülerek uç donanımda (edge device) gerçek zamanlı kalite kontrolüne entegre edilebilir.

9. Sonuç

Bu çalışmada, metal döküm parçalarında yüzey anomalisi tespiti amacıyla denetimsiz öğrenme tabanlı bir sistem tasarlanmış ve kapsamlı biçimde değerlendirilmiştir. Deneysel sonuçlar üç temel bulguyu ortaya koymaktadır:

1. **Denetimsiz yaklaşım etkilidir:** AUC > 0.95 düzeyindeki tutarlı performans, etiketli anomali verisi gerektirmeyen bu yaklaşımın endüstriyel kalite kontrolü için güçlü bir seçenek olduğunu kanıtlamaktadır.

2. **Doku bilgisi üstündür:** LBP, AUC $= 0.964$ ve Precision $= 0.94$ değerleriyle HOG ve HOG+LBP'yi geride bırakmıştır.

3. **Özellik birleştirme dikkat gerektirir:** HOG+LBP beklenen sinerjiyi ortaya koyamamıştır; dikkatli özellik seçimi ve ağırlıklı birleştirme stratejileri gelecek çalışmalarda araştırılmalıdır.

Bu çalışma, el-crafted özellikler ve klasik anomali tespiti yöntemlerinin sanayi görüntü denetiminde ciddi bir potansiyel taşıdığını somut biçimde göstermektedir.

Kaynakça

1. Bergmann, P., Fauser, M., Sattlegger, D., & Steger, C. (2019). *MVTec AD – A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection*. CVPR 2019, 9592–9600.

2. Bergmann, P., Löwe, S., Fauser, M., Sattlegger, D., & Steger, C. (2019). *Improving Unsupervised Defect Segmentation by Applying Structural Similarity to Autoencoders*. VISIGRAPP 2019, 372–380.

3. Dalal, N., & Triggs, B. (2005). *Histograms of Oriented Gradients for Human Detection*. CVPR 2005, 886–893.

4. Ojala, T., Pietikainen, M., & Maenpaa, T. (2002). *Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 24(7), 971–987.

5. Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). *LOF: Identifying Density-Based Local Outliers*. ACM SIGMOD 2000, 93–104.

6. Schölkopf, B., Platt, J. C., Shawe-Taylor, J., Smola, A. J., & Williamson, R. C. (2001). *Estimating the Support of a High-Dimensional Distribution*. Neural Computation, 13(7), 1443–1471.

7. Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). *Isolation Forest*. IEEE ICDM 2008, 413–422.

8. Pang, G., Shen, C., Cao, L., & Hengel, A. v. d. (2021). *Deep Learning for Anomaly Detection: A Review*. ACM Computing Surveys, 54(2), 1–38.

9. Roth, K., Pemula, L., Zepeda, J., Schölkopf, B., Brox, T., & Gehler, P. (2022). *Towards Total Recall in Industrial Anomaly Detection*. CVPR 2022, 14318–14328.

10. Rudolph, M., Wandt, B., & Rosenhahn, B. (2021). *Same Same But DifferNet: Semi-Hard Negative Sampling for Unsupervised Anomaly Detection*. WACV 2021, 3895–3905.